



手写数字识别经典卷积神经网络对比

学院 机电工程学院

班级 机设 2 班

学号 202531032070

姓名 范宇桐

2026 年 6 月 6 日

摘 要

为了验证经典卷积神经网络在带噪声的 RGB 色盲检测数字图像上的鲁棒性,本研究选取 LeNet-5、AlexNet、VGG 系列、ResNet 系列、Densnet 系列等经典 CNN 模型,在人工合成的色盲检测数字的数据集(训练集 60000 张,测试集 10000 张, 128×128)上开展对比实验。实验结果是: InceptionV3 在批次 16 时取得 99.87% 的最高测试准确率,参数量较大的 VGG19 准确率最低。综合来看除了 VGG 系列其他模型都具有良好的鲁棒性。

目录

1	引言	4
2	方法论	4
2.1	LeNet-5	4
2.2	AlexNet	4
2.3	VGG 系列	5
2.4	GoogLeNet (Inception v1)、InceptionV3	5
2.5	ResNet 系列	6
2.6	DenseNet 系列	6
3	实验：在色盲检测数字图像上的模型测试	7
3.1	实验设置	7
3.1.1	数据集	7
3.1.2	模型	7
3.1.3	设置	7
3.1.4	实验设计	8
3.2	搜索空间	8
3.3	推论	8
3.4	各模型结果分析	9
4	总结与展望	10

1 引言

现有研究多聚焦于经典卷积神经网络在 MNIST 灰度手写数字集上的性能对比，而缺乏对各模型在特定检测场景下的鲁棒性的研究，本研究在原实验基础上引入色彩与噪声维度，以色盲检测数字图片作为训练集，测试模型在 RGB 图片、多结构分布且非线性连续场景下的鲁棒性和泛化性以达到更贴近真实应用的效果。在工业实践中，应用场景往往灵活多变，易面临各类噪声干扰，仅选用实验室场景下表现良好的模型并非最优选择。因此，本研究通过科学严谨的实验数据对比，筛选出噪声场景下仍保持高准确率的模型，为图像识别技术的工业落地提供参考。

2 方法论

本研究选取经典 CNN 模型作为基准模型，所有模型仅针对色盲检测数字集 (128×128 RGB) 将输入通道从 1 调整为 3，不修改模型核心结构与参数，保证实验对比公平性。各模型核心设计如下：

2.1 LeNet-5

LeNet-5 是 LeCun 等人于 1998 年提出的首个实用卷积神经网络 (LeCun et al., 1998)，奠定了「卷积-池化-全连接」的经典 CNN 架构。

卷积层 C1: 输入 $32 \times 32 \times 3$ ，6 个 5×5 卷积核（步长 1，无 padding），输出 $28 \times 28 \times 6$ 特征图，激活函数为 tanh；

池化层 S2: 2×2 平均池化（步长 2），输出 $14 \times 14 \times 6$ 特征图，降低特征维度；

卷积层 C3: 16 个 5×5 卷积核（步长 1，无 padding），输入 $14 \times 14 \times 6$ ，输出 $10 \times 10 \times 16$ 特征图，激活函数为 tanh；

池化层 S4: 2×2 平均池化（步长 2），输出 $5 \times 5 \times 16$ 特征图；

全连接层 F5: 输入 $5 \times 5 \times 16$ 展平为 400 维，映射到 120 维特征，激活函数为 tanh；

全连接层 F6: 120 维映射到 84 维特征，激活函数为 tanh；

输出层 RBF: 84 维映射到 10 类（数字 0-9），采用径向基函数实现分类。

2.2 AlexNet

AlexNet 是 Krizhevsky 等人在 2012 年 ImageNet 竞赛中提出的深度 CNN 模型 (Krizhevsky et al., 2012)

卷积层 Conv1: 输入 $32 \times 32 \times 3$ ，96 个 11×11 卷积核（步长 4，padding=2），输出 $8 \times 8 \times 96$ ，ReLU 激活，后接 3×3 最大池化（步长 2）；

卷积层 Conv2: 256 个 5×5 卷积核（步长 1，padding=2），输入 $8 \times 8 \times 96$ ，输出 $8 \times 8 \times 256$ ，ReLU 激活，后接 3×3 最大池化（步长 2）；

卷积层 Conv3: 384 个 3×3 卷积核 (步长 1, padding=1), 输入 $4 \times 4 \times 256$, 输出 $4 \times 4 \times 384$, ReLU 激活;

卷积层 Conv4: 384 个 3×3 卷积核 (步长 1, padding=1), 输入 $4 \times 4 \times 384$, 输出 $4 \times 4 \times 384$, ReLU 激活;

卷积层 Conv5: 256 个 3×3 卷积核 (步长 1, padding=1), 输入 $4 \times 4 \times 384$, 输出 $4 \times 4 \times 256$, ReLU 激活, 后接 3×3 最大池化 (步长 2);

全连接层 FC6: 输入 $2 \times 2 \times 256$ 展平为 1024 维, 映射到 4096 维, ReLU 激活, Dropout (rate=0.5) 正则化;

全连接层 FC7: 4096 维映射到 4096 维, ReLU 激活, Dropout (rate=0.5) 正则化;

输出层 FC8: 4096 维映射到 10 类, Softmax 分类。

关键模块特性: 引入 ReLU 解决梯度消失问题, Dropout 减少过拟合。

2.3 VGG 系列

VGG 由 Simonyan 和 Zisserman 于 2014 年提出 (Simonyan and Zisserman, 2014), 核心设计是「 3×3 小卷积核堆叠替代大卷积核」。本研究选取 VGG11、VGG13、VGG16、VGG19 及对应 BN 版本

卷积块 1: 2 个 3×3 卷积层 (64 通道, 步长 1, padding=1) $\rightarrow$ ReLU $\rightarrow 2 \times 2$ 最大池化 (步长 2), 输入 $32 \times 32 \times 3 \rightarrow$ 输出 $16 \times 16 \times 64$;

卷积块 2: 2 个 3×3 卷积层 (128 通道, 步长 1, padding=1) $\rightarrow$ ReLU $\rightarrow 2 \times 2$ 最大池化 (步长 2), 输出 $8 \times 8 \times 128$;

卷积块 3: 3 个 3×3 卷积层 (256 通道, 步长 1, padding=1) $\rightarrow$ ReLU $\rightarrow 2 \times 2$ 最大池化 (步长 2), 输出 $4 \times 4 \times 256$;

卷积块 4: 3 个 3×3 卷积层 (512 通道, 步长 1, padding=1) $\rightarrow$ ReLU $\rightarrow 2 \times 2$ 最大池化 (步长 2), 输出 $2 \times 2 \times 512$;

卷积块 5: 3 个 3×3 卷积层 (512 通道, 步长 1, padding=1) $\rightarrow$ ReLU $\rightarrow 2 \times 2$ 最大池化 (步长 2), 输出 $1 \times 1 \times 512$;

全连接层: $1 \times 1 \times 512$ 展平 $\rightarrow$ 4096 维 $\rightarrow$ ReLU $\rightarrow$ Dropout(0.5) $\rightarrow$ 4096 维 $\rightarrow$ ReLU $\rightarrow$ Dropout(0.5) $\rightarrow$ 10 类 Softmax。

BN 版本在卷积层后增加批归一化层, 其余结构与基础版完全一致。

2.4 GoogLeNet (Inception v1)、InceptionV3

GoogLeNet (Inception v1) 是 Szegedy 等人在 2014 年提出的多尺度特征融合模型 (Szegedy et al., 2015), 核心为 Inception 模块多分支特征融合。本研究同时采用 InceptionV1 与 InceptionV3

核心模块: Inception 模块——通过 4 个并行分支提取多尺度特征, 最终在通道维度拼接:

分支 1 (1×1 卷积): 1×1 卷积核 (步长 1, padding=0) → ReLU, 提取细粒度特征;
 分支 2 (3×3 卷积): 1×1 卷积降维 → 3×3 卷积 (padding=1) → ReLU, 提取中等尺度特征;
 分支 3 (5×5 卷积): 1×1 卷积降维 → 5×5 卷积 (padding=2) → ReLU, 提取大尺度特征;
 分支 4 (池化 + 卷积): 3×3 最大池化 (padding=1) → 1×1 卷积降维 → ReLU, 保留低频特征。

网络整体结构: 前置卷积与池化层 + 堆叠 Inception 模块 + 全局平均池化 + Softmax 分类层。

2.5 ResNet 系列

ResNet 由 He 等人于 2015 年提出 (He et al., 2016), 核心是「残差连接 (Shortcut)」解决超深网络梯度消失问题。本研究选取 ResNet18、ResNet34、ResNet50

核心模块: 残差块——包含 2 个 3×3 卷积层, 残差连接分同维度与跨维度两种:
 同维度残差连接: shortcut 直接直通, 公式为:

$$y = \mathcal{F}(x, \{W_i\}) + x$$

跨维度残差连接: shortcut 采用 1×1 卷积调整通道数, 公式为:

$$y = \mathcal{F}(x, \{W_i\}) + W_s x$$

整体结构: 前置卷积池化层 + 多组残差块 + 全局平均池化 + 全连接分类层。

2.6 DenseNet 系列

DenseNet 由 Huang 等人于 2017 年提出 (Huang et al., 2017), 核心为「密集连接」最大化特征复用。本研究选取 DenseNet121、DenseNet169

核心模块:

密集块 (Dense Block): 每一层与前面所有层特征拼接, 第 l 层输入为:

$$x_l = H_l([x_0, x_1, \dots, x_{l-1}])$$

过渡层 (Transition Layer): BN + 1×1 卷积降维 + 2×2 平均池化, 控制维度增长。

整体结构: 前置卷积池化层 + 多个密集块与过渡层 + 全局平均池化 + 全连接分类层。

表 1: Optimal Hyperparameters and Mean Accuracy of Each Model

Model	Batch Size	Learning Rate	Weight Decay	Mean Accuracy
LeNet5	64	0.001	0.0	98.89%
ResNet18	16	0.0005	0.0	99.77%
ResNet34	32	0.0001	0.0	99.76%
ResNet50	16	0.0001	0.0	99.80%
VGG11	16	0.001	5e-05	10.21%
VGG13	16	0.0005	5e-05	10.33%
VGG16	16	0.001	5e-05	10.28%
VGG19	16	0.0005	5e-05	10.02%
AlexNet	32	0.0001	0.0005	99.39%
InceptionV1	64	0.001	0.0001	99.78%
InceptionV3	16	0.001	0.0	99.87%
DenseNet121	32	0.001	0.0001	99.83%
DenseNet169	32	0.001	0.0001	99.84%

3 实验：在色盲检测数字图像上的模型测试

3.1 实验设置

3.1.1 数据集

本文实验所用数据集为人工合成的数字识别测试集，由 Python 脚本程序化生成。该数据集均为色盲测试图片，每张图像包含单张数字字符（0-9），共包含 60000 张训练集图片和 10000 张测试集图片。所有图片均为 128×128 像素的 RGB 图，涵盖 0 ~ 9 共 10 个数字类别。每个模型最多训练 150 轮，使用耐心值为 10 的退火机制训练；对所有模型做必要的数据集适配，保证所有模型在统一数据条件下测试。

3.1.2 模型

我们使用了 LeNet5、AlexNet、VGG11/13/16/19、ResNet18/34/50、InceptionV1(V3)、DenseNet121/169 等经典模型进行实验，最大程度上保证其架构与原始论文一致，仅做了 RGB 数据集的适配和超参数调整。

3.1.3 设置

软件环境为 Python 3.10.11、torch 2.2.0+cu118、numpy 1.24.3、CUDA 11.8
硬件环境为 NVIDIA RTX 5070 GPU（8GB 显存）。实验采用测试集准确率和测试集损

失作为模型性能的评价指标。采用早停策略，实际迭代轮次可能因模型和批次而异。

3.1.4 实验设计

本实验采用两阶段网格搜索策略对全部模型进行超参数优化，具体流程如下：

1. 阶段 1：快速评估

- 对所有参数组合进行 10 轮快速评估；
- 固定随机种子：42；
- 基于评估结果筛选最优参数组合。

2. 阶段 2：余弦退火训练

- 采用筛选后的最优参数进行 200 轮训练；
- 训练策略：余弦退火学习率调度（CosineAnnealingLR）；
- 早停策略：耐心值（Patience）设为 15；
- 分别使用随机种子 45、46、47 重复实验，验证模型稳定性。

3.2 搜索空间

本次网格搜索的超参数空间定义如下：

- 批次大小（batch_size）：16、32、64；
- 学习率（learning_rate）：0.001、0.0005、0.0001；
- 权重衰减（weight_decay）：0.0、0.0001、0.0005、 5×10^{-5} 。

3.3 推论

本实验在统一的数据集、训练策略和评价标准下，对 7 类共 13 种经典卷积神经网络模型进行了系统性对比。实验结果显示：**模型结构设计是决定其在带噪声 RGB 数字图像上鲁棒性的核心因素，不同架构模型的性能呈现出显著的两极分化特征**。在最优超参数配置下，ResNet、DenseNet、Inception、AlexNet 及 LeNet-5 模型的平均测试准确率均达到 98.89% 99.87%，展现出极强的噪声鲁棒性和泛化能力；而 VGG 系列所有模型的平均测试准确率仅为 10.02% 10.33%，接近 10 分类任务的随机猜测水平，在本实验条件下无法完成有效的数字识别任务。

从模型结构维度分析，具备**残差连接、密集特征复用或多尺度特征融合机制**的网络架构，能够通过跨层信息传递和多维度特征提取，有效抑制噪声对有效特征的干扰，保证深层网络中信息的稳定流动。相比之下，VGG 系列采用的纯 3×3 卷积堆叠架构缺

乏上述机制，噪声信号可能在网络逐层传播过程中不断累积放大，最终导致深层特征严重退化，无法提取出可用于分类的有效数字特征。

超参数对模型性能的影响呈现出明显的结构依赖性：在本实验的搜索空间内，权重衰减对不同模型的影响差异最为显著。VGG 系列在最优配置中均采用了 5×10^{-5} 的权重衰减，但仍无法改善其分类性能；而鲁棒性优异的 ResNet、InceptionV3 和 LeNet-5 模型在无权重衰减的条件下即可达到最优效果，这表明其网络结构本身具备更强的抗过拟合和抗噪声能力。批次大小和学习率则无统一的最优取值，需根据模型的深度和参数量进行针对性调整。

此外，实验结果还表明：**在本任务的数据集规模和噪声强度下，模型参数量与最终性能不存在正相关关系**。轻量级模型 LeNet-5 仅用约 6 万个参数即可达到 98.89% 的准确率，中等参数量的 ResNet18 与深度更深的 DenseNet169 均实现了接近 100% 的识别精度；而参数量最大的 VGG19（约 1.4 亿个参数）性能反而最差。这一发现证实，在低质噪声图像识别任务中，网络结构的合理性远比单纯增加模型规模更为重要。

3.4 各模型结果分析

基于最优超参数下的平均测试准确率，将所有模型分为高性能鲁棒模型和条件失效模型两大类，结合其核心结构特点按模型家族逐一分析：

1. 基础轻量级模型：LeNet-5

LeNet-5 在批次大小 64、学习率 0.001、无权重衰减的配置下取得了 98.89% 的平均准确率。作为最经典的浅层卷积神经网络，其“卷积-池化-全连接”的简洁架构具有参数量小、计算效率高的优势。在噪声场景下，较少的网络层数有效避免了噪声信号的逐层累积，同时降低了过拟合风险，能够快速收敛并稳定提取数字的核心轮廓特征，证明轻量级模型在特定工业识别场景中具备极高的实用价值。

2. 经典深度模型：AlexNet

AlexNet 在最优超参数配置下实现了 99.39% 的平均准确率。其核心创新的 ReLU 激活函数有效缓解了深层网络训练中的梯度消失问题，Dropout 正则化机制进一步抑制了过拟合，提升了模型泛化能力。实验结果验证了 AlexNet 经典架构在噪声 RGB 图像上的优秀鲁棒性，可适配复杂的色彩分布与噪声干扰场景。

3. 残差网络家族：ResNet 系列

ResNet18/34/50 均取得 99.76% 99.80% 的顶尖准确率，整体性能稳定优异。残差连接机制通过恒等映射路径，彻底解决了深层网络的梯度消失问题，在噪声数据中保证原始有效特征的稳定传递。其中 ResNet50 性能最优，批次大小 16、小学习率的配置最契合其深层网络结构，进一步提升了特征表达能力与鲁棒性。

4. 纯卷积堆叠模型：VGG 系列

VGG11/13/16/19 的准确率均稳定在 10% 左右，即便采用小批次训练与权重衰减

优化，性能也无明显提升。核心原因是纯 3×3 卷积堆叠的架构缺乏有效跨层信息传递机制，噪声会在逐层卷积中淹没浅层有效特征，最终引发严重的特征退化与梯度弥散。该结论仅适用于本实验场景，VGG 在干净图像数据集上仍具备常规性能。

5. 多尺度融合模型：Inception 系列

InceptionV3 以 99.87% 的准确率成为本实验最优模型，InceptionV1 也达到 99.78%。Inception 多分支模块可并行提取不同尺度特征并融合，全面捕捉数字的纹理、轮廓与结构信息，极大增强了模型对噪声和色彩畸变的适应性，是鲁棒性提升的核心关键。

6. 密集连接模型：DenseNet 系列

DenseNet121/169 分别实现 99.83%、99.84% 的准确率，性能仅次于 InceptionV3。密集连接机制实现了全层特征复用与信息传递，最大化保留浅层数字特征，避免噪声场景下的特征丢失，在鲁棒性与识别精度之间实现了最优平衡。

综合所有模型的实验结果，InceptionV3、DenseNet169、ResNet50 为本实验场景下鲁棒性最优的模型；轻量级模型 LeNet-5、AlexNet 的准确率虽略低，但计算成本更低、推理速度更快，均可直接应用于带噪声的色盲检测数字识别工业落地任务。

4 总结与展望

本实验证实，在噪声较多的 RGB 图像识别场景中，小模型的鲁棒性显著优于大模型，特征信息的跨层传递能力是决定模型性能的关键因素。具体而言，具备残差连接、密集连接或多尺度特征融合结构的模型，最终性能远优于深度深、参数量大但仅依赖 ReLU 激活函数的传统深层模型，二者性能呈现明显两极分化。

后续研究将从两方面展开：一是采用更大规模的数据集和批次大小测试大模型，观察数据量与维度提升对大模型性能的影响；二是在 VGG 模型中替换 ReLU 激活函数，验证激活函数对噪声数据特征学习的影响。

参考文献

- He, K., Zhang, X., Ren, S., and Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 770–778, Las Vegas, NV, USA. IEEE.
- Huang, G., Liu, Z., Van Der Maaten, L., and Weinberger, K. Q. (2017). Densely connected convolutional networks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 4700–4708, Honolulu, HI, USA. IEEE.
- Krizhevsky, A., Sutskever, I., and Hinton, G. E. (2012). Imagenet classification with deep convolutional neural networks. In *Advances in Neural Information Processing Systems*, volume 25, pages 1097–1105, Red Hook, NY, USA. Curran Associates Inc.
- LeCun, Y., Bottou, L., Bengio, Y., and Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324.
- Simonyan, K. and Zisserman, A. (2014). Very deep convolutional networks for large-scale image recognition. In *International Conference on Learning Representations*. arXiv:1409.1556.
- Szegedy, C., Liu, W., Jia, Y., Sermanet, P., Reed, S., Anguelov, D., Erhan, D., Vanhoucke, V., and Rabinovich, A. (2015). Going deeper with convolutions. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 1–9, Boston, MA, USA. IEEE.